随行帮办 · 指标说明

2026 iCAN 大学生创新创业大赛 · 快手 AI 未来创造者挑战赛（10 月月赛 · AI 产品实现方向） | 辅助材料：指标采集方式与实测值

本页回答一个问题：**说明书里那些数字是怎么来的。**全部指标取自运行中的真实埋点，不靠估算；任何人都能按下表右侧的命令自行复现。

2.0s / 2.8s
模型通道延迟 P50 / P95（端到端含 HTTP）

621
单次调用平均 token

220
自动化用例，全部通过

12 / 12
低保复核流程引导步数命中

一、指标定义与采集方式

指标	定义（怎么算）	采集位置	当前值 / 判读
引导准确率	Agent 指向的控件 ID 与流程图声明的目标控件一致的比例	契约测试（`tests/navigation.test.ts`）+ 埋点 `guide.issued` 的 `targetControlId`	100%（12/12 节点）。这是硬约束：流程图里写哪个控件，界面就只高亮哪个，模型无权改动
响应延迟	引导接口从收到请求到返回的时间，含模型调用与 HTTP 往返	埋点 `guide.issued.latencyMs`；`/api/metrics` 输出 p50 / p95	模型通道 P50 2037ms / P95 2804ms；规则通道 P50 2.3ms；改写缓存命中 0ms（不发起调用）
调用成本	累计 token ÷ 模型调用次数	`/api/metrics` → `llm.tokens` / `llm.calls`	23 次调用共 14281 tokens，均值 621 tokens/次。规则通道与缓存命中为 0 调用
纠偏成功率	走错后 1 步内回到正确流程的比例	埋点 `rescue.triggered`，含误入屏幕与纠偏话术	100%（演示用例）。纠偏不是「返回」两个字，而是说明「这里是医保，办低保要回上一页」
护栏命中	支付、人脸、验证码、授权协议等节点被降级为「本人确认」的次数	埋点 `guardrail.blocked`；规则在 `guardrails.ts` 硬编码	低保复核 2 次（人脸 / 身份）、生活缴费 2 次（支付 / 确认）。命中后模型无法代按
说错率	结果页反馈「它说错了」占全部反馈的比例，按人头计数，改主意以最后一次为准	埋点 `feedback.given`；`/api/metrics` → `quality.wrongRate`	三档分开统计。「没办成」多卡在系统或材料，是流程问题；「说错了」才是措辞或定位问题，两者混算会把可修的平均掉
通道可用性	模型不可用时流程能否走完	熔断器 + `/api/meta`；无密钥冒烟测试	可完整走完。连续失败即熔断 60 秒，界面徽标变为「模型降级 · 规则兜底」并如实告知

二、怎么复现这些数字

命令	产出
`npm install && npm run verify`	类型检查 + 代码风格 + 220 项用例 + 构建。任何一项失败即中断
`npm run demo:check`	一条命令跑完：环境自检 → 静态检查 → 单测 → 构建 → 起服务 → 冒烟 → 五项真实浏览器探针 → 截图 → 生成自包含 HTML 报告。**探针出现 ✗ 或非零退出码，整条命令失败**
`curl /api/metrics`	上述延迟、token、反馈与埋点计数的实时快照

三、口径说明（避免误读）

① **用 P95 而非平均值**：引导是有人盯着屏幕等的同步调用，一次 5 秒长尾会被平均值藏起来。② **失败分两类记账**：`network` 与 `timeout` 分开统计——前者改配置永远改不好，混算会掩盖真因。③ **样本量如实标注**：本页为 2026-10-31 20:22 运行快照，真实用户可用性测试尚未开展（见说明书 7.4 节）。